Materi Retrieval-Augmented Generation (RAG) Part 1: Embedding & Vector Database membahas konsep dasar RAG, yaitu teknik yang digunakan untuk membantu sistem AI memberikan jawaban berdasarkan informasi dari dokumen atau sumber data tertentu. RAG bekerja dengan cara mencari informasi yang relevan dari dokumen, kemudian memasukkan informasi tersebut ke dalam prompt agar AI dapat menghasilkan jawaban yang lebih sesuai dengan sumber. RAG memiliki beberapa keunggulan, seperti mengurangi kemungkinan hallucination atau jawaban yang tidak sesuai fakta, menggunakan informasi yang lebih baru, serta memungkinkan AI mengakses dokumen pribadi atau khusus tanpa harus melatih ulang model. Dalam proses RAG terdapat dua tahapan utama, yaitu indexing dan querying. Tahap indexing digunakan untuk mempersiapkan dokumen agar dapat dicari, sedangkan querying digunakan untuk mencari informasi yang sesuai dengan pertanyaan pengguna.

Pada tahap indexing, terdapat empat proses utama, yaitu Load, Split, Embed, dan Store. Load merupakan proses membaca dokumen, misalnya file PDF, agar teks di dalamnya dapat digunakan oleh program. Split adalah proses membagi teks menjadi bagian-bagian kecil yang disebut chunk supaya informasi lebih mudah diproses dan dicari. Embed merupakan proses mengubah teks menjadi representasi angka atau vektor menggunakan model embedding. Sementara itu, Store adalah proses menyimpan vektor, teks asli, dan metadata ke dalam vector database. Setelah dokumen berhasil disimpan, sistem dapat melakukan pencarian ketika pengguna memberikan pertanyaan. Pertanyaan tersebut akan diubah menjadi vektor menggunakan model embedding yang sama dengan model yang digunakan saat indexing, kemudian sistem mencari chunk yang paling relevan berdasarkan kemiripan vektornya.

Embedding merupakan proses mengubah teks menjadi kumpulan angka atau vektor yang menggambarkan makna dari teks tersebut. Dengan embedding, sistem tidak hanya mencari kata yang sama persis, tetapi juga dapat menemukan teks yang memiliki makna serupa meskipun menggunakan kata-kata berbeda. Salah satu metode untuk mengukur kemiripan vektor adalah cosine similarity. Nilai cosine similarity yang mendekati 1 menunjukkan bahwa dua vektor memiliki arah yang semakin mirip, sedangkan nilai yang mendekati 0 menunjukkan tingkat kemiripan yang rendah. Dalam penggunaan ChromaDB dengan pengaturan cosine distance, semakin kecil nilai distance, semakin mirip teks yang dibandingkan. Oleh karena itu, pemilihan model embedding sangat penting karena model yang digunakan untuk mengubah dokumen dan pertanyaan harus sama agar proses pencarian dapat berjalan dengan baik.

Materi ini juga membahas chunking, yaitu proses membagi dokumen menjadi potongan-potongan teks dengan ukuran tertentu. Ukuran chunk berpengaruh terhadap kualitas pencarian informasi. Jika chunk terlalu kecil, informasi yang diperoleh bisa kehilangan konteks, sedangkan jika terlalu besar, informasi yang tidak relevan dapat ikut terbawa sehingga hasil pencarian menjadi kurang tepat. Untuk mengatasi masalah tersebut, digunakan overlap atau bagian teks yang saling tumpang tindih antara satu chunk dengan chunk berikutnya agar informasi penting tidak terputus. Selain itu, materi memperkenalkan ChromaDB sebagai vector database yang digunakan untuk menyimpan dan mencari data berdasarkan kemiripan vektor. ChromaDB dapat menyimpan embedding, teks asli, serta metadata seperti nama file, halaman, dan bagian dokumen. Pada praktikum ini digunakan Python, Sentence Transformers, PyPDF,

LangChain Text Splitters, dan ChromaDB untuk membangun sistem pencarian dokumen sederhana.

Praktikum dibagi menjadi tiga kegiatan utama. Lab 1 berfokus pada membaca dokumen PDF dan membagi teks menjadi chunk dengan ukuran 500, 1000, dan 1500 karakter, kemudian mengamati jumlah chunk serta memeriksa apakah ada kalimat atau tabel yang terpotong. Lab 2 berfokus pada membangun indeks dokumen menggunakan ChromaDB dari beberapa file PDF, kemudian mencoba pencarian dengan berbagai pertanyaan untuk mengetahui apakah sistem dapat menemukan informasi yang relevan, termasuk pertanyaan yang menggunakan kata-kata berbeda dari dokumen. Lab 3 berfokus pada evaluasi hasil pencarian menggunakan 15 pertanyaan pengujian dengan mengukur Hit@k dan Mean Reciprocal Rank (MRR). Hit@k digunakan untuk mengetahui apakah jawaban yang benar muncul dalam sejumlah hasil pencarian teratas, sedangkan MRR mengukur posisi hasil pertama yang benar. Melalui ketiga praktikum tersebut, mahasiswa diharapkan memahami cara membangun sistem RAG sederhana, mengelola embedding dan vector database, serta mengevaluasi kualitas pencarian informasi dari dokumen.